

An Introduction to Exponential Family

中南财经政法大学 应用统计 1701 曹奕涵

指数族分布通常有很多很好的性质，包括在贝叶斯推断、统计计算、信息论中，都有很广泛的应用。本文将从指数族开始介绍。

1 Exponential Family

我们假设空间 χ 中存在某个 base measure μ ，并且存在一个有效统计量： $\phi: \chi \rightarrow R^d$ 。对于这样一个函数 ϕ ，令 $\theta \in R^d$ 为规范参数的相关向量，那么：

Definition 1 对于一个函数 ϕ 和一个基础度量 μ ，指数族为一系列的具有以下密度函数 p_θ 的分布：

$$p_\theta(x) = \exp(\langle \theta, \phi(x) \rangle - A(\theta))$$

并且，函数 A 是对数配分函数（也可以称为累积量生成函数）：

$$A(\theta) := \log \int_{\chi} \exp(\langle \theta, \phi(x) \rangle) d\mu(x)$$

且 A 是有限的。

一般来说，以下定义会更加方便一些：

Definition 2 对于一个基函数 $h: \chi \rightarrow R_+$ ，指数族分布表示为：

$$p_\theta(x) = h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$$

以上就是指数族分布的一个较为基础的定义，为了更加正式的定义指数族分布，我们先介绍指数倾斜 (exponential tilting) 的构造：

Definition 3 设 (χ, F_χ, ν) 上的分布 P 具有概率密度： $\frac{dP}{d\nu} =: h$ ，由 Borel 函数可以导出矩母函数：

$$M(\xi) = E_{X \sim P}[e^{\xi^T T(X)}] = \int_{\chi} e^{\xi^T T(x)} h(x) d\nu(x)$$

对于 $\Xi \in \{\xi \in R^m : M(\xi) \leq \infty\}$ 记累计生成函数: $K(\xi) = \log M(\xi)$, 那么:

$$f_\xi(x) := \frac{1}{M(\xi)} e^{\xi^T T(x)} h(x) = \exp\{\xi^T T(x) - K(\xi)\} h(x)$$

定义了一族分布 $\{f_\xi dv : \xi \in \Xi\}$, 该分布为自然指数族 (natural exponential family)。

上述定义就为指数倾斜, 可以查看[UCB stat210A](#)的代码, 了解如何在 R 中构造一个指数倾斜。

下面我们来定义一般的指数族分布:

Definition 4 一个参数族 $P = \{P_\theta : \theta \in \Theta\}$ 定义在空间 (χ, F_χ, v) 上, 如果概率密度有:

$$\frac{dP_\theta}{dv}(x) = \exp\{\xi(\theta)^T T(x) - B(\theta)\} h(x)$$

, 称 $\Xi = \{\xi(\theta) : \theta \in \Theta\}$ 为自然参数空间, 重新参数化, 得到:

$$\{\exp\{\xi^T T(x) - B(\theta(\xi))\} h(x) dv(x) : \xi \in \Xi\}$$

为指数族的规范形式。

2 Some Examples on Exponential Family

2.1 Bernoulli Distribution:

令 μ 为 $\{0, 1\}$ 上的计数测度, $\theta = \log \frac{p}{1-p}$, 那么, 伯努利可以写成:

$$\begin{aligned} P(X = x) = p(x) &= p^x (1-p)^{1-x} = \exp(x \log p - x \log(1-p)) \\ &= \exp(x \log \frac{p}{1-p} + \log(1-p)) \quad (1) \\ &= \exp(x\theta - \log(1 + e^\theta)) \end{aligned}$$

它的对数配分为: $A(\theta) = \log(1 + e^\theta)$.

2.2 Poisson Distribution:

泊松分布的参数 $\lambda > 0$ 。令 μ 为 $\{0, 1, \dots\}$ 上的计数测度, $\theta = \log \lambda$, 那么:

$$p(x) = \frac{1}{x!} \lambda^x e^{-\lambda} = \exp(x \log \lambda - \lambda) \frac{1}{x!} = \exp(x\theta - e^\theta) \frac{1}{x!} \quad (2)$$

其中, $h(x) = \frac{1}{x!}$, 对数配分 $A(\theta) = e^\theta$

2.3 Normal Distribution:

正态分布中, 令 μ 为 $(-\infty, \infty)$ 上的勒贝格测度, 并且, 重参数化 $N(\mu, \Sigma)$, 有 $\Theta = \Sigma^{-1}$, $\theta = \Sigma^{-1}$, 得到可以用欧式内积 \langle, \rangle 表达的:

$$p_{\theta, \Theta}(x) \propto \exp(\langle \theta, x \rangle + \frac{1}{2} \langle xx^T, \Theta \rangle)$$

为了表达的更加易懂, 也可以写成:

$$f_{\mu, \sigma}(x) = \frac{1}{\sqrt{(2\pi)}} \exp\left\{-\frac{x^2}{2\sigma^2} + \frac{x\mu}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{\log(\sigma^2)}{2}\right\}$$

同样的, 前面三项可以看作是内积, 对数配分为后面的 $\frac{\log(\sigma^2)}{2}$ 。

2.4 Geometric Distribution:

几何分布中, 参数 $p \in (0, 1)$, 对于 N^* 上的计数测度有:

$$f_p(x) = (1-p)^{x-1} p = \exp\{(x-1)\log(1-p) + \log p\}$$

对数配分 $A(\theta) = \log p$

2.5 Binomial Distribution:

二项分布中, 参数 $p \in (0, 1)$, 对于 $\{0, 1, \dots, n\}$ 上的计数测度, 有:

$$f_p(x) = C_n^x p^x (1-p)^{n-x} = \exp\{x \logit(p) + n \log(1-p)\} C_n^x$$

其中, 对数配分为 $A(\theta) = -n \log(1-p)$, $h(x) = C_n^x$, \logit 代表 $\logit(p)$ 。

2.6 Negative Binomial Distribution:

负二项同上，计数测度为 N ， $h(x) = C_{r+x-1}^{r-1}$

2.7 Multinomial Distribution:

多项分布服从 $Multi(n, p_0, p_1, \dots, p_k) : p_j \in (0, 1), \sum_{j=0}^k p_j = 1$ ，其离散测度：

$$\{(x_0, x_1, \dots, x_k) : x_j \in N, \sum_{j=0}^k x_j = n\}$$

上有：

$$f_p(x) = \exp\left\{\sum_{j=1}^k x_j \log\left(\frac{p_j}{p_0}\right) + n \log(p_0)\right\} \frac{n!}{x_0! x_1! \dots x_k!}$$

2.8 Gamma Distribution:

伽马分布 $Gamma(k, \theta) : k > 0, \theta > 0$ ，对于 R_+ 上的勒贝格测度有：

$$f_{k,\theta}(x) = \frac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-x/\theta} = \exp\{(k-1)\log(x) - x/\theta - k\log(\theta) - \log\Gamma(k)\}$$

2.9 Exponential Distribution:

指数分布 $\exp(\lambda) = Gamma(1, \lambda^{-1})$ ：

$$f_\lambda = \exp\{\log \lambda - \lambda x\}$$

2.10 χ^2 Distribution:

$\chi_d^2 = Gamma(d/2, 2)$ ：

$$\begin{aligned} \chi_d^2 &\propto x^{d/2-1} \exp\{-x/2\} \\ &= \exp\left\{\left(\frac{d}{2} - 1\right) \log x - \frac{x}{2}\right\} \end{aligned} \quad (3)$$

3 Some Properties of Exponential Families

定义指数族分布的一个原因，就是指数族分布常常有很好的性质。从前面的分析可以看出来，一些平常我们使用的分布，都可以表示成指数族分布

的形式。对于优化的 Bayes Proceudre(我不知道怎么翻译,可能是贝叶斯决策吧,详见[MIT stat655](#),大概讲的就是贝叶斯决策问题跟平方损失),有着很好的鲁棒性。更多的,他们的分析性质也很好。比如,指数族分布中对数配分的图形常常使得指数族分布的估计更加简单。对于样本来说,假设我们要估计参数 θ , 使用极大似然法(也就是最小化对数损失),那么根据指数族分布的表达式,我们可以写成:

$$\begin{aligned} \min_{\theta} \quad & \sum_{i=1}^n \log \frac{1}{p_{\theta}(X_i)} \\ = \min \quad & \sum_{i=1}^n [-\langle \theta, \phi(X_i) \rangle + A(\theta)] \end{aligned} \tag{4}$$

这说明,在这个最小化中是不存在局部最小的,也就是在进行梯度运算的时候,不会陷入局部最小出不来。

当然,指数族分布也有很好的统计性质。对于来自指数族分布的样本,希望估计参数,比如 θ , 此时 $\sum_{i=1}^n T(X_i)$ 就是充分统计量,其中 $T(x)$ 来自 $f_{\theta}(x) = \exp(\xi(\theta)^T T(x) - B(\theta))h(x)$ 。这个看起来有点像因子分解定理,实际上的确用到了因子分解定理来证明。

除此以外,广义线性模型与指数族分布联系也非常密切。指数族分布就常常可以用来“建造”GLM。

4 参考资料

- Stanford Lecture Notes for stat311/ee377, John Duchi, March 13, 2019
- 知乎用户 @ 纯粹的专栏文章: [指数族分布](#)
- Stanford Lecture Notes for CS229, Part5 Generalized Linear Models, Andrew NG